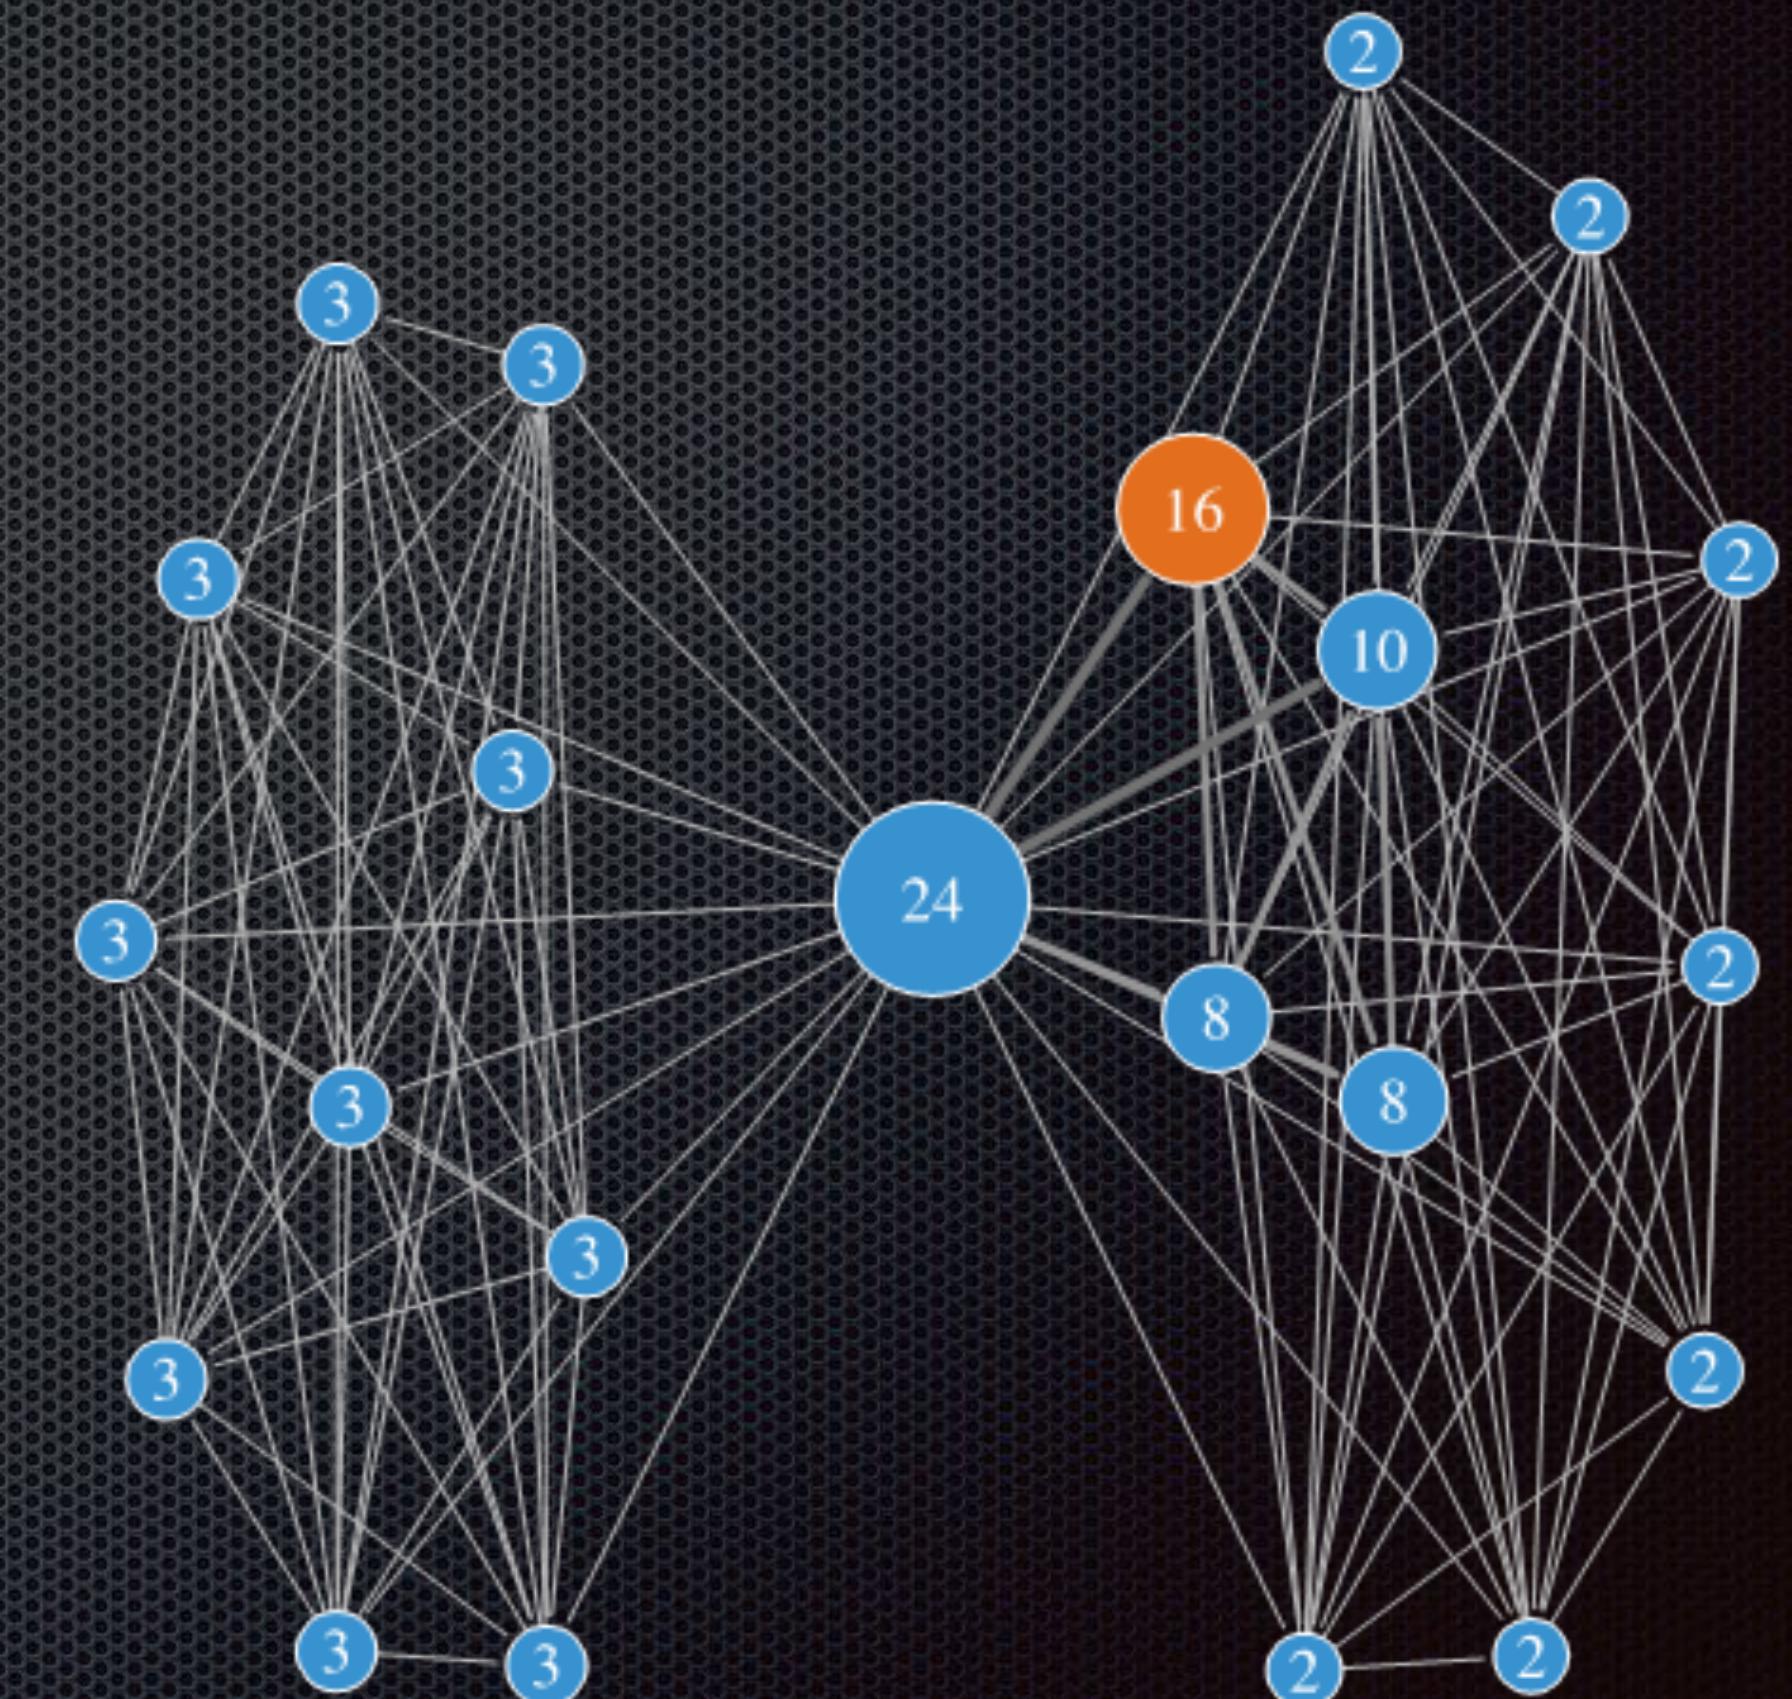


Inferência Probabilística

Redes Bayesianas



Robson Fernandes

Acadêmico

Mestrando em Matemática, Estatística e Computação Aplicadas (Data Science & Machine Learning) - USP
Especialização em Reconhecimento de Padrões e Análise de Imagens - UNICAMP
Pós-Graduado em Arquitetura de Software Distribuído - PUC-MG
MBA em Engenharia de Software Orientada a Serviços – SOA – METROCOMP
Certificado – JavaScript e HTML5 Developer – W3C INTERNACIONAL
Autor do Livro Gestão da Tecnologia da Informação: Teoria e Prática

Profissional

Cientista de Dados Sênior – Finch Soluções
Docente Pós-Graduação - MBA em Data Science & Machine Learning - UNIP
Docente Pós-Graduação em Engenharia de Software - USC
Docente Graduação em Ciência da Computação - UNIP

Site

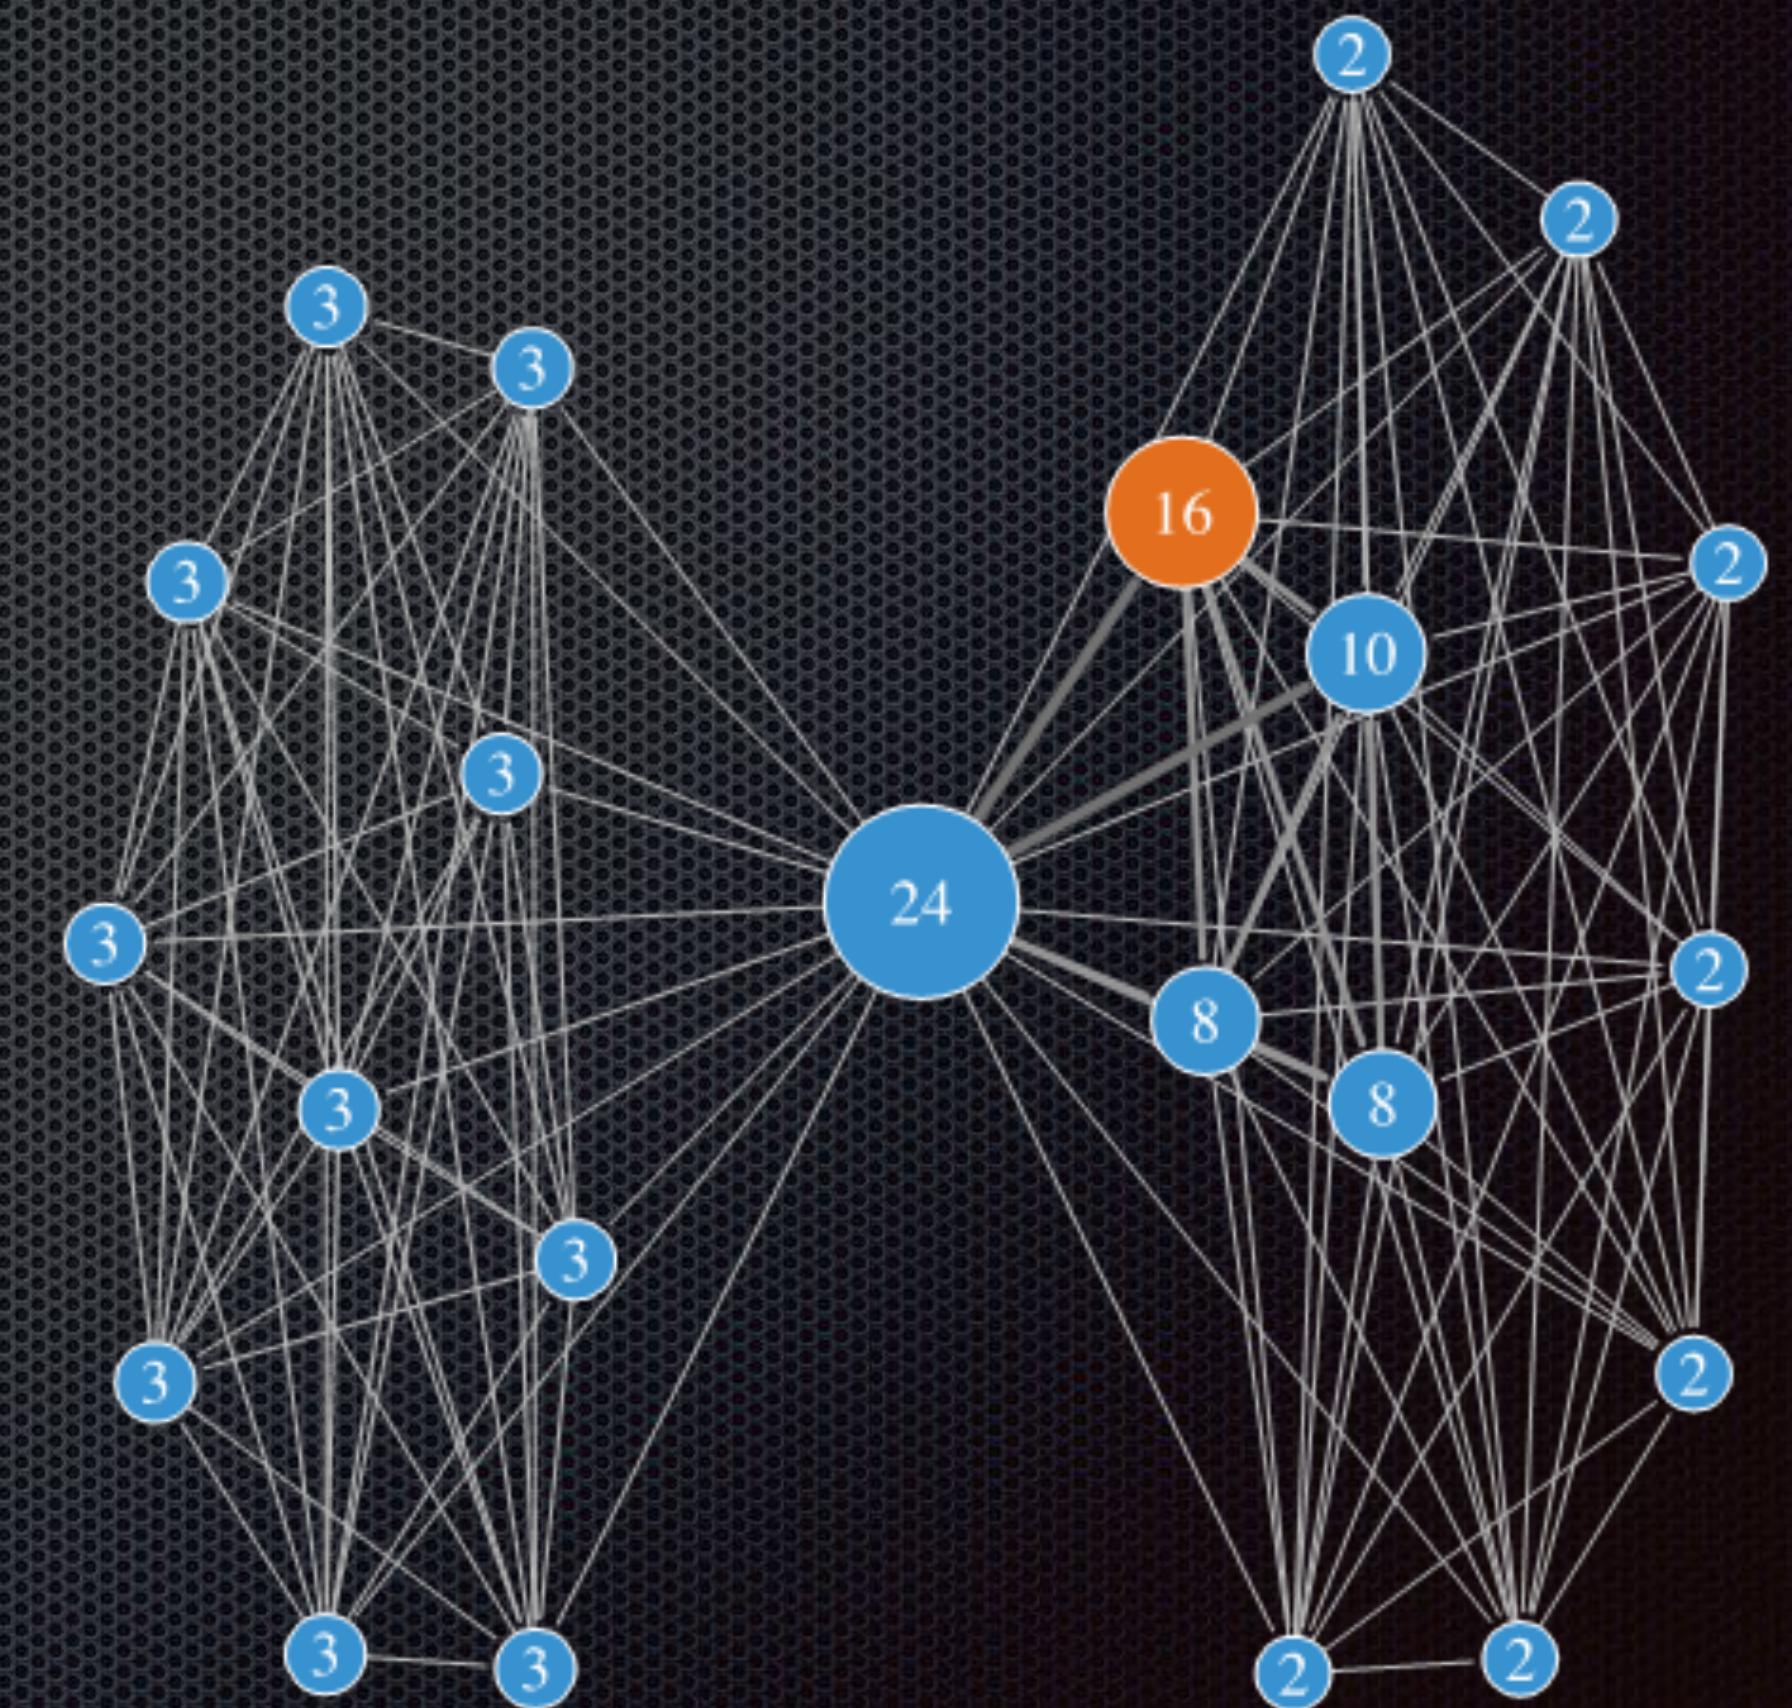
<http://robsonfernandes.net>

e-mail

robson.fernandes@usp.br ou robs.fernandes@outlook.com

Agenda

- Introdução
 - Computação Tradicional vs Aprendizado de Máquina
 - Paradigmas de Aprendizado de Máquina
 - Redes Bayesianas
 - Introdução
 - Estrutura de Dados
 - Especificação
 - Relações de Causalidade
 - Probabilidade Condicional
 - Teorema de Bayes
 - Como Construir uma Rede Bayesiana
 - Inferência
 - Bibliotecas de Desenvolvimento
 - Conclusão



Introdução

- Computação Tradicional **vs** Aprendizagem de Máquina



Computação Tradicional **vs** AM

- Computação Tradicional
- Escreve algoritmo detalhando como resolver um problema.
- Aprendizado de Máquina
- Aprende a resolver um problema observando seus dados.

Computação Tradicional **vs** AM

- Computação Tradicional
- Pessoas programam
- Aprendizado de Máquina
- Computadores programam.

Computação Tradicional **vs** AM

- Computação Tradicional
- Programa que funciona 90% das vezes é pode ser considerado ruim.
- Aprendizado de Máquina
- Modelo que acerta 90% das vezes pode ser considerado muito bom e eficiente.

Paradigmas de Aprendizado de Máquina

- Simbólico
- Buscam aprender construindo representações simbólicas
(Expressão lógica, Árvores de Decisão Regras)
- Estatístico
- Buscam métodos estatísticos
(Aprendizado Bayesiano, Séries Temporais)

Paradigmas de Aprendizado de Máquina

- Conexionista
- Modelos inspirados no modelo biológico do sistema nervoso
(Redes Neurais)
- Evolutivo
- Teoria de Darwin
(Algoritmos Genéticos)

Redes Bayesianas - Introdução

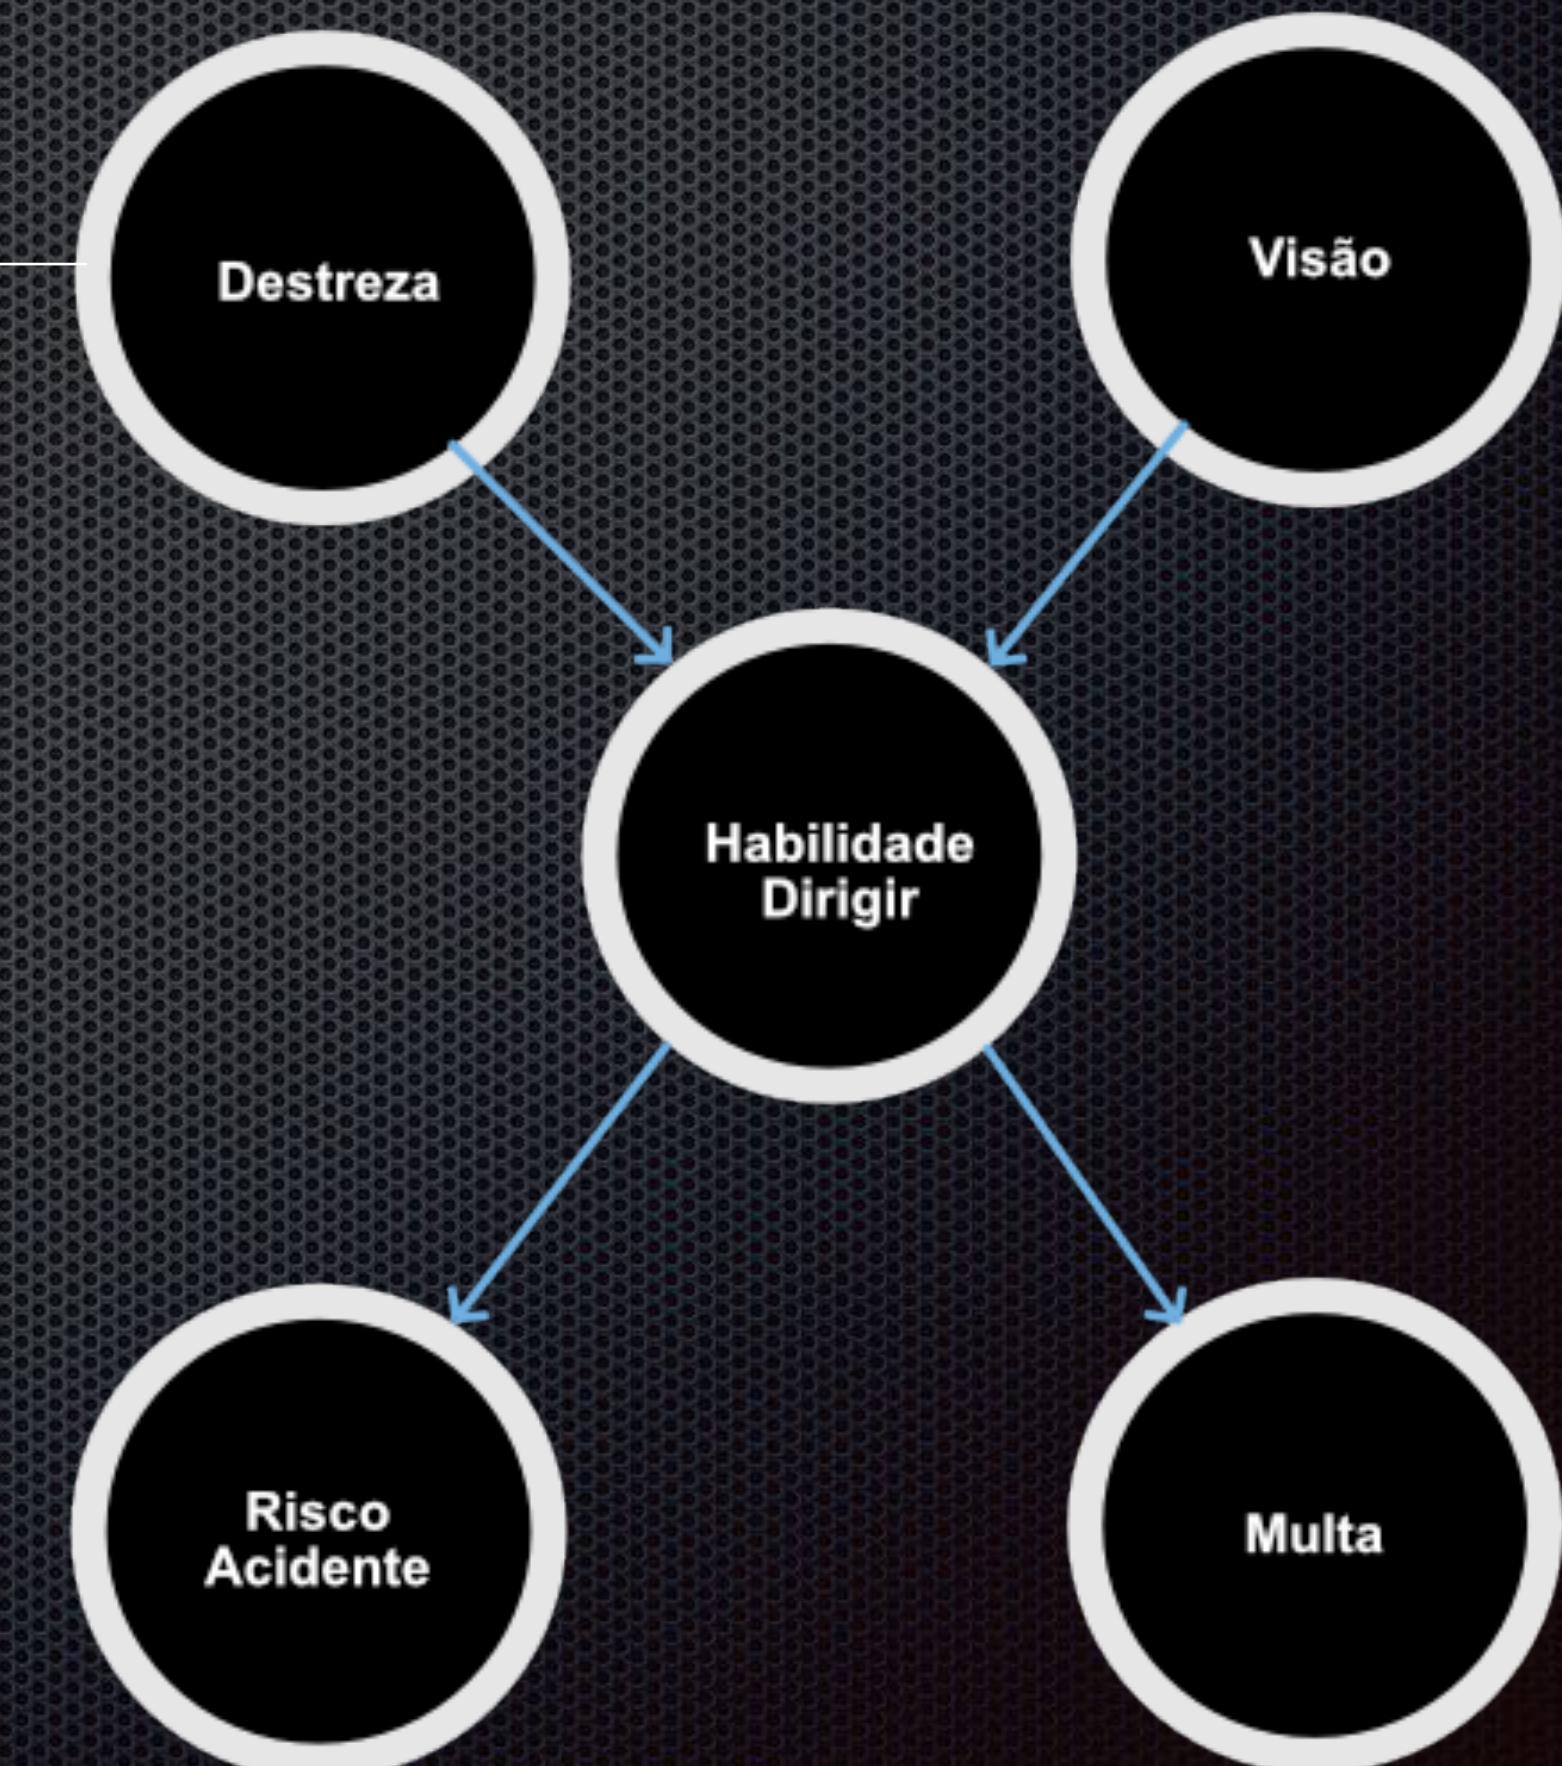
- As Redes Bayesianas foram desenvolvidas início dos anos 80 para facilitar a tarefa de predição e “abdução” em sistemas de Inteligência Artificial (AI) (Pearl, 2000).
- Redes Bayesianas (RB) também conhecidas como redes de opinião, redes causais, gráficos de dependência probabilística.
- São modelos gráficos para raciocínio (conclusões) baseado na incerteza.



Redes Bayesianas - Estrutura de Dados

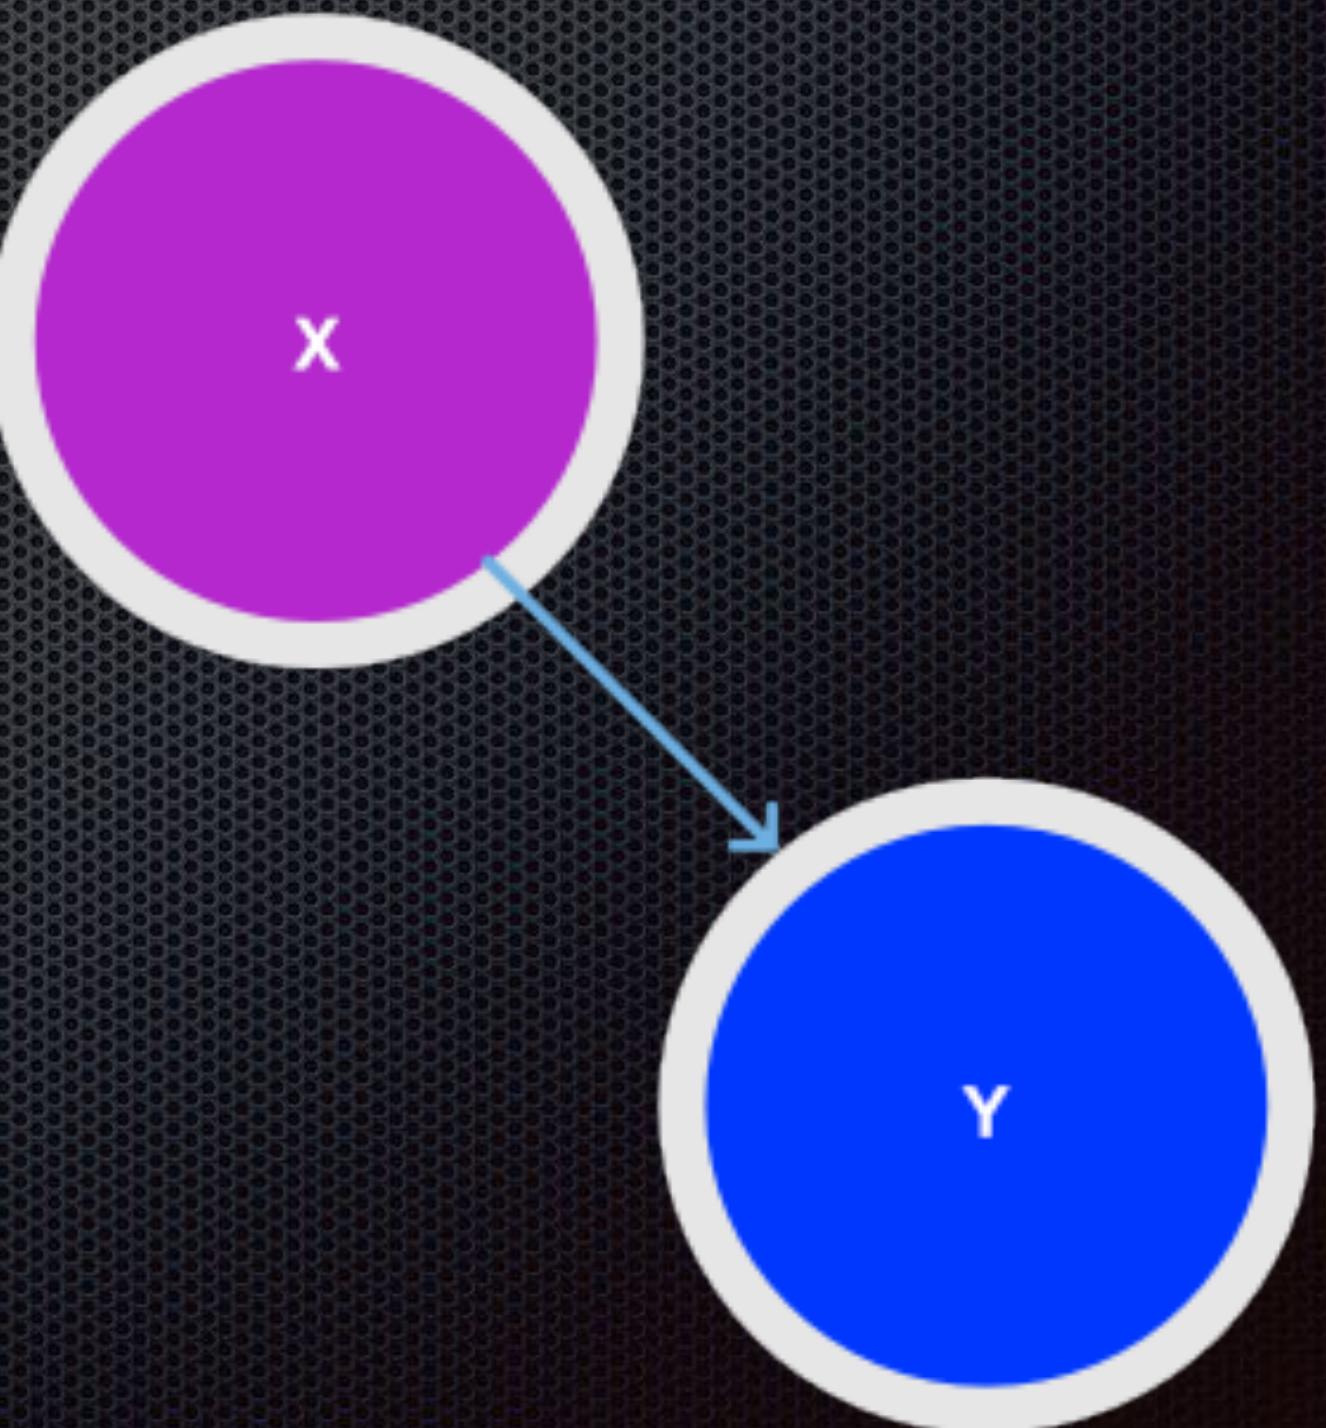
- Grafo direcionado, onde cada nó possui uma informação com uma probabilidade quantitativa.

Destreza	
SIM	20
Não	80



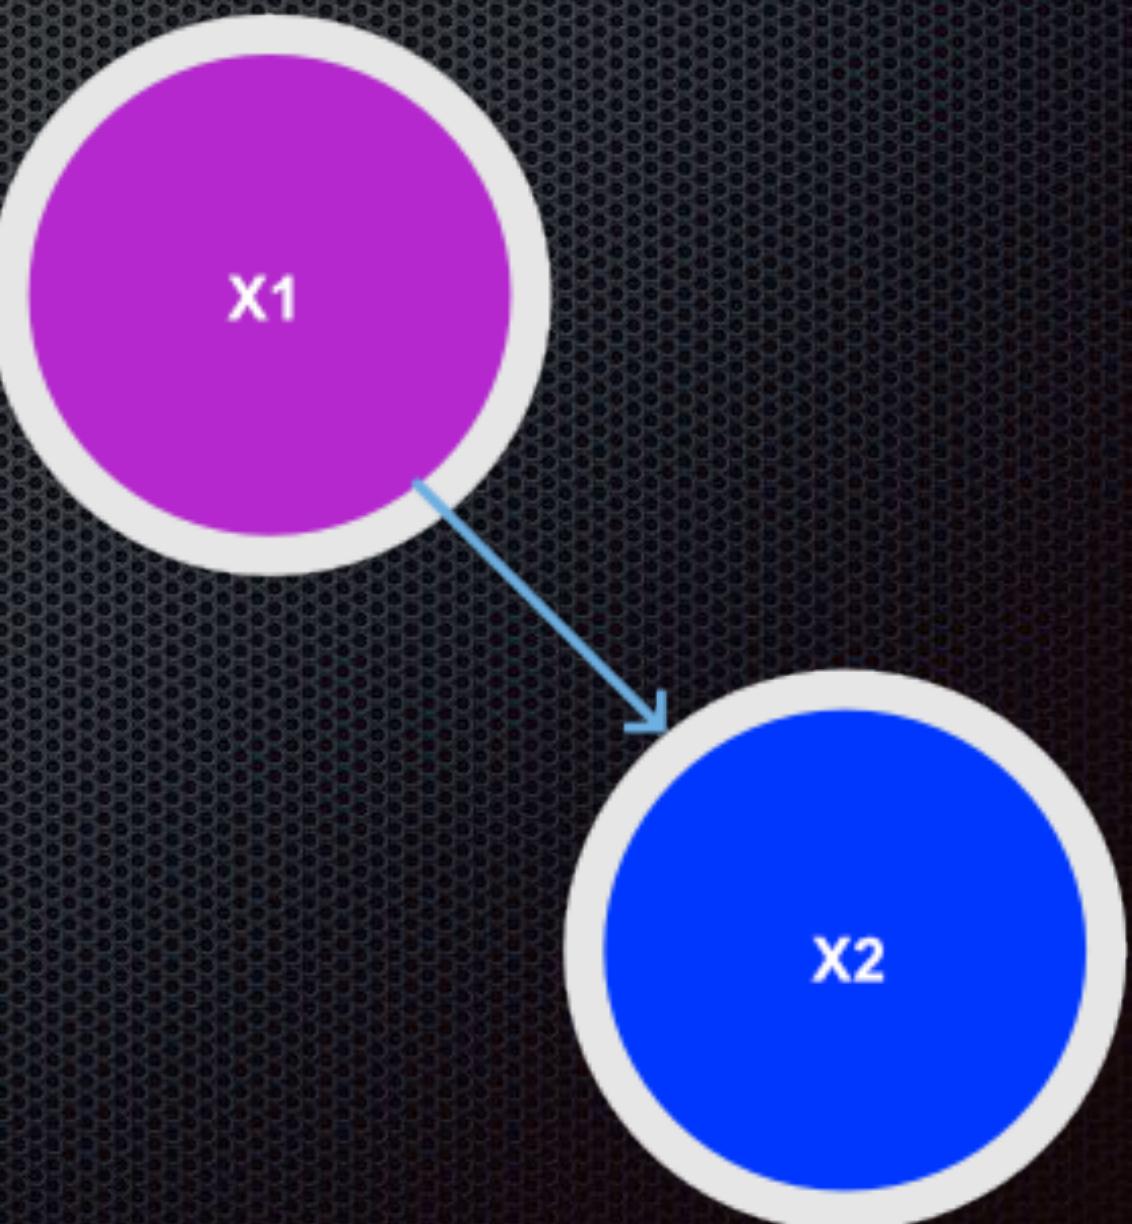
Redes Bayesianas - Especificação

- Um conjunto de variáveis randômicas compõem os **nós** da rede
- Um conjunto de **links** ou setas conectam os pares de nós.
- Por exemplo:
 - se há uma seta do nó **X** para o nó **Y**, é lido da seguinte maneira:
 - **X** é dito ser o **pai** de **Y**.

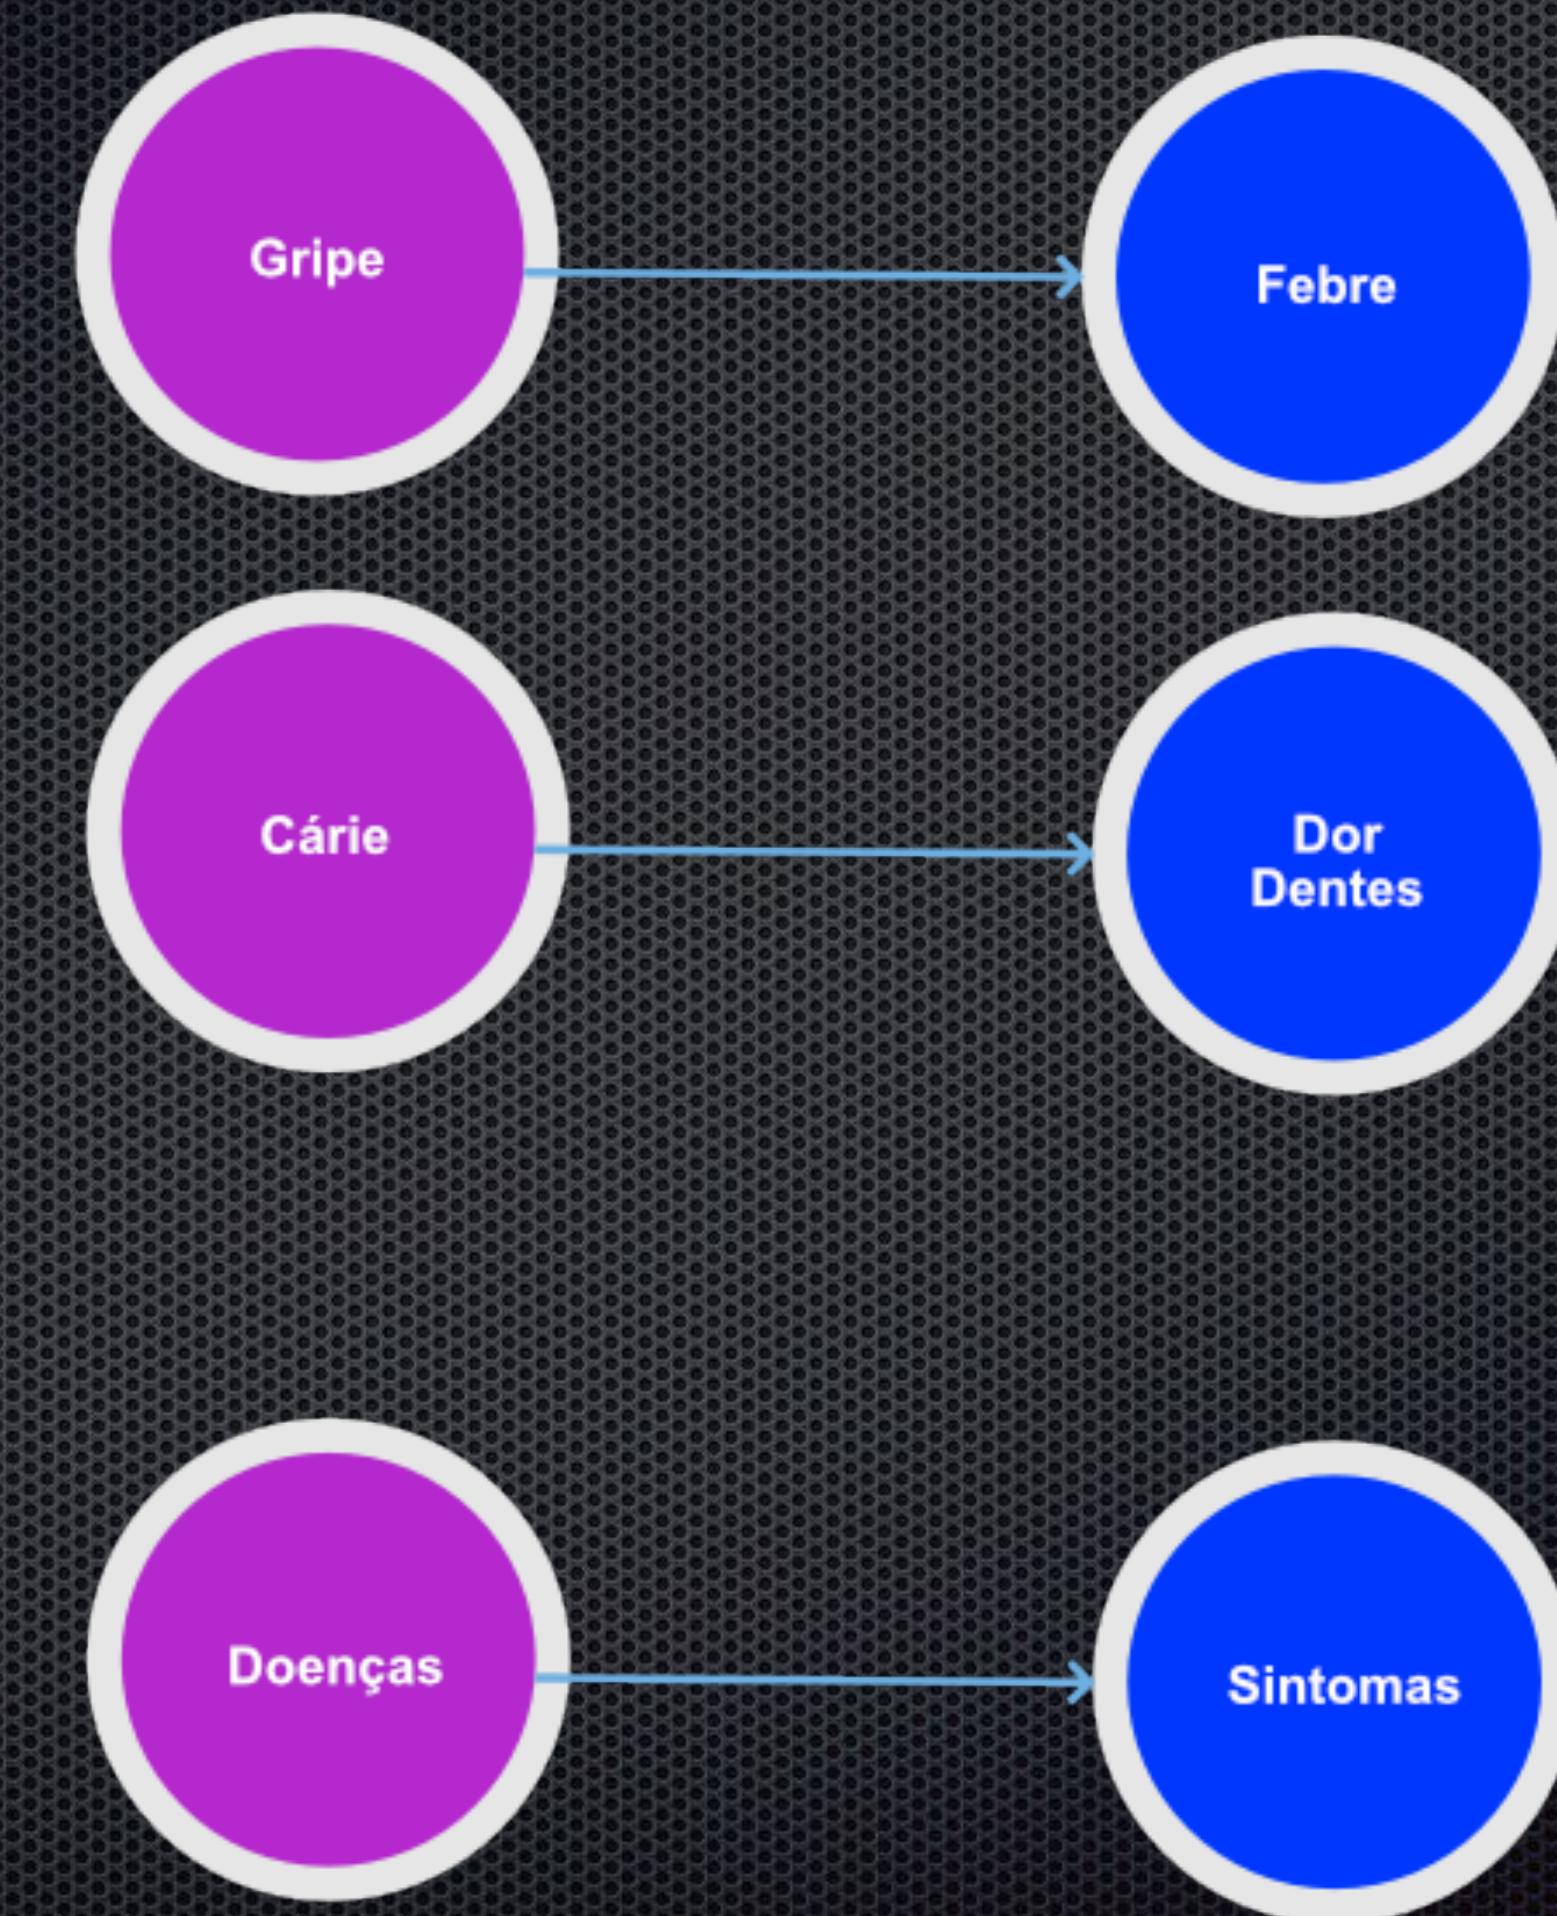


Redes Bayesianas - Relações de Causalidade

- O mais usual é a Rede Bayesiana representar relações de causalidade entre variáveis de um sistema.
- Seja X_1 e X_2 duas variáveis de um sistema em estudo, a figura ao lado pode representar uma Rede Bayesiana em que:
- X_1 é a causa de X_2 .



Redes Bayesianas - Relações de Causalidade - Em Medicina



Redes Bayesianas - Probabilidade Condicional

- A probabilidade condicional trata da probabilidade de ocorrer um evento **A**, tendo ocorrido um evento **B**, ambos do espaço amostral **S**, ou seja, ela é calculada sobre o evento **B** e não em função o espaço amostral **S**.
- A probabilidade de ocorrência de um evento **A** em relação a um evento ocorrido **B** é expressa como:
- $P(A | B)$



Redes Bayesianas - Teorema de Bayes

- Mostra a relação entre uma probabilidade condicionada e a sua inversa
- Dados dois eventos A e B

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

- $P(A)$ e $P(B)$ são as probabilidades à priori de A e de B.
- $P(A|B)$ e $P(B|A)$ é a probabilidade condicionada (ou à posteriori) de A e B.



Redes Bayesianas - Como construir

- Defina um conjunto de variáveis X que descrevam o domínio
- Defina a estrutura da RB:
 - Para cada variável $X_i \in X$ crie um nó na Rede
 - Determine os nós $Pais(X_i)$ dentre os nós que já estejam na rede e que tenham influência direta em X_i
- Defina os pesos da RB:
 - Para os nós que não possuem pais defina as probabilidades priori
 - Para os nós que possuem pais defina as probabilidades condicionais

Obs: A estrutura e os pesos da RB podem ser aprendizados a partir de uma base de dados

Redes Bayesianas - Construção Passo a Passo



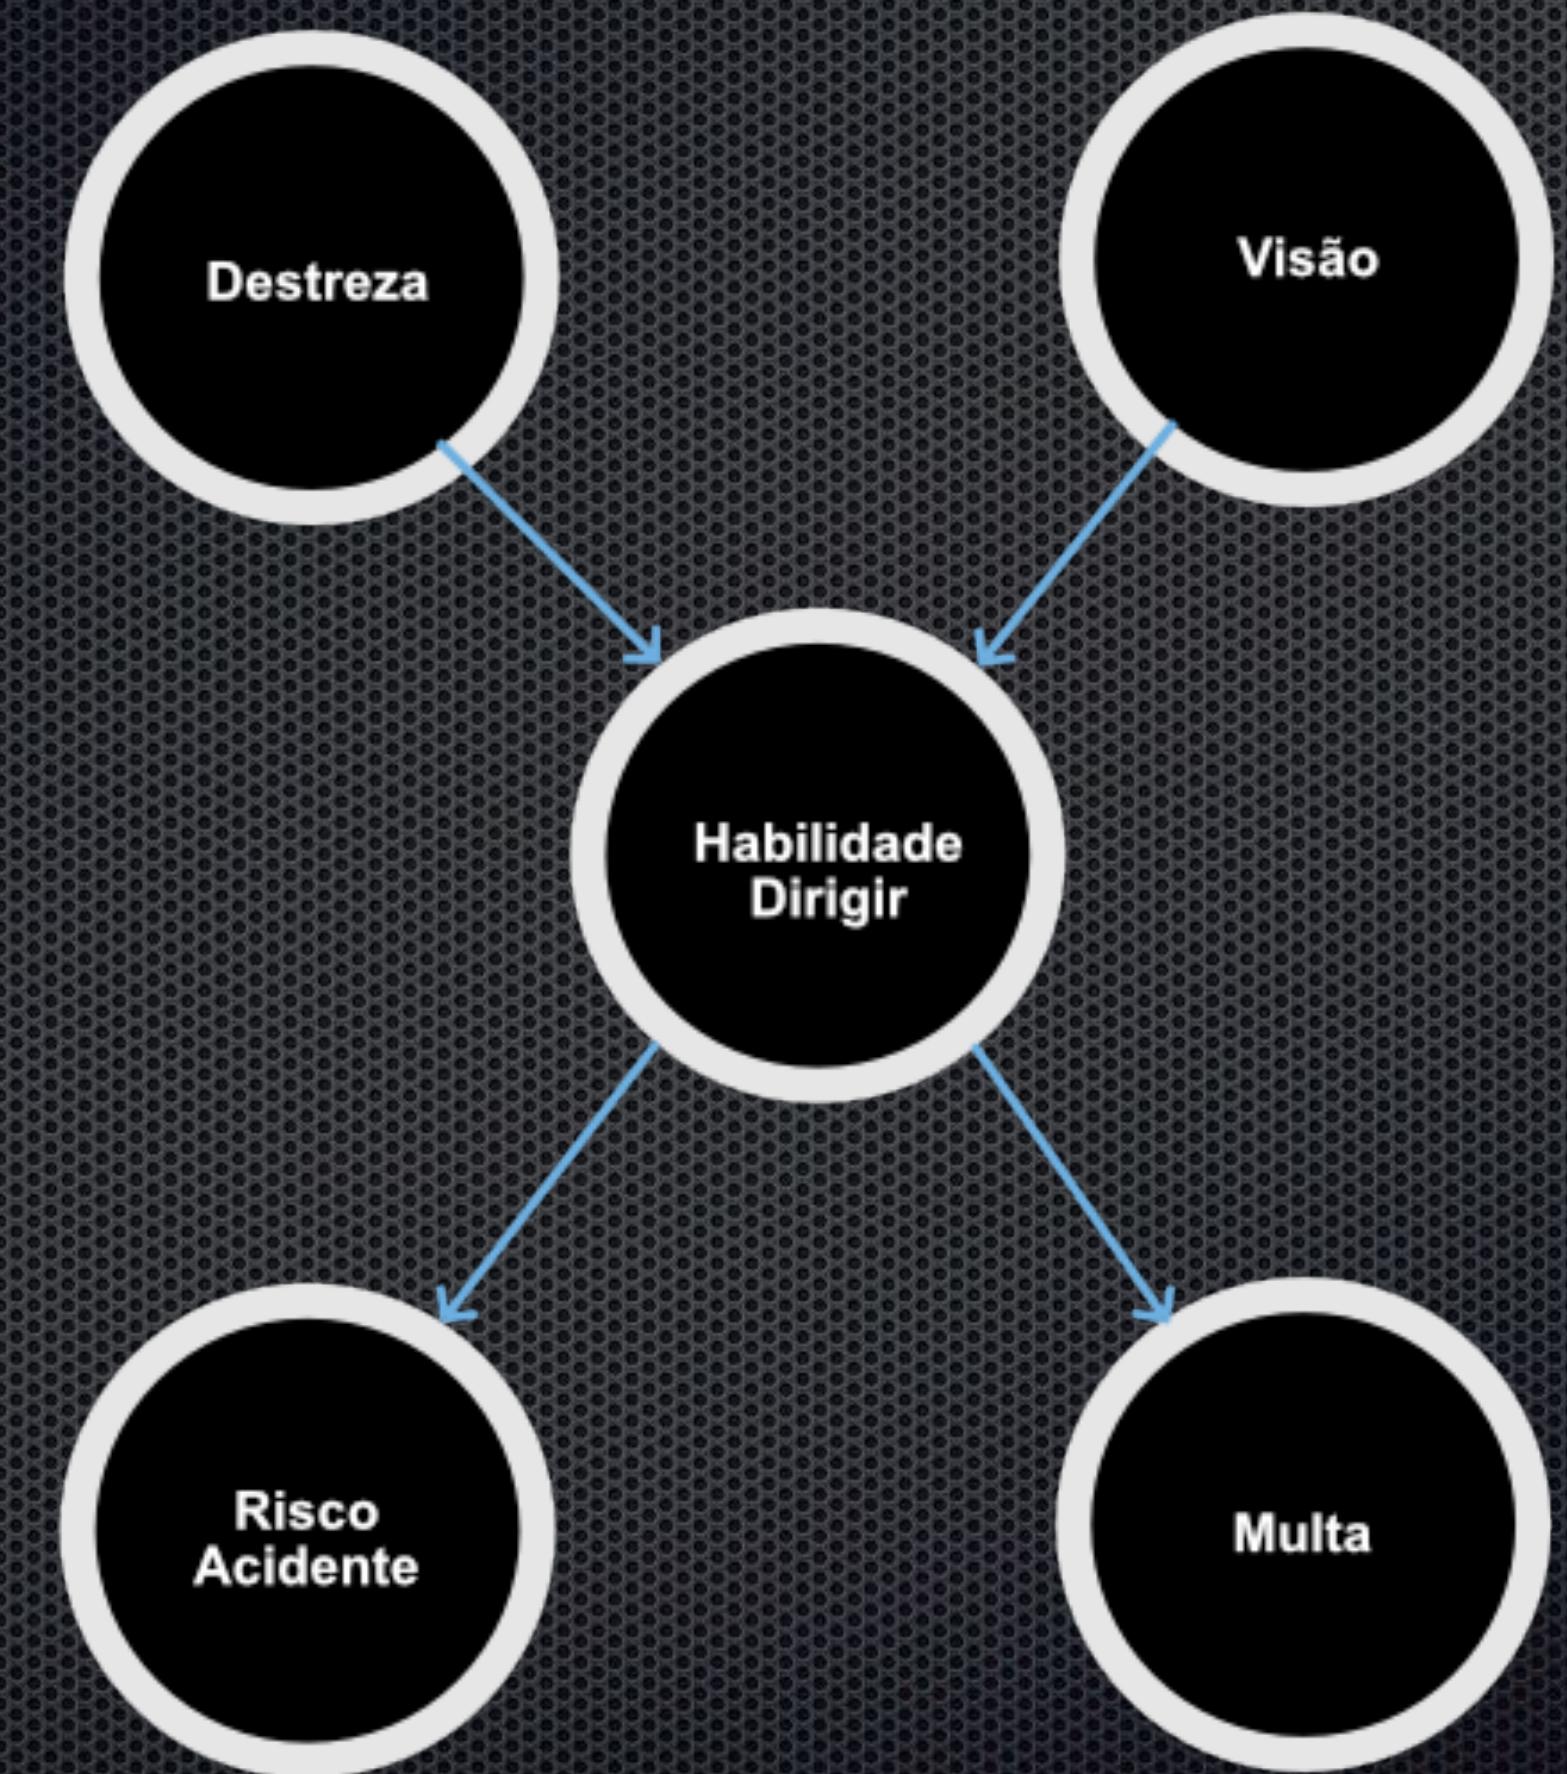
Redes Bayesianas - Construção Passo a Passo - Exemplo

- Exemplo: Desenvolver um sistema que, dado alguns atributos da capacidade física de uma pessoa prevê sua habilidade de dirigir. Além disso, o sistema deverá com base na habilidade de dirigir de uma pessoa prever qual a probabilidade de ocorrer um acidente ou ela ser autuada com uma multa.

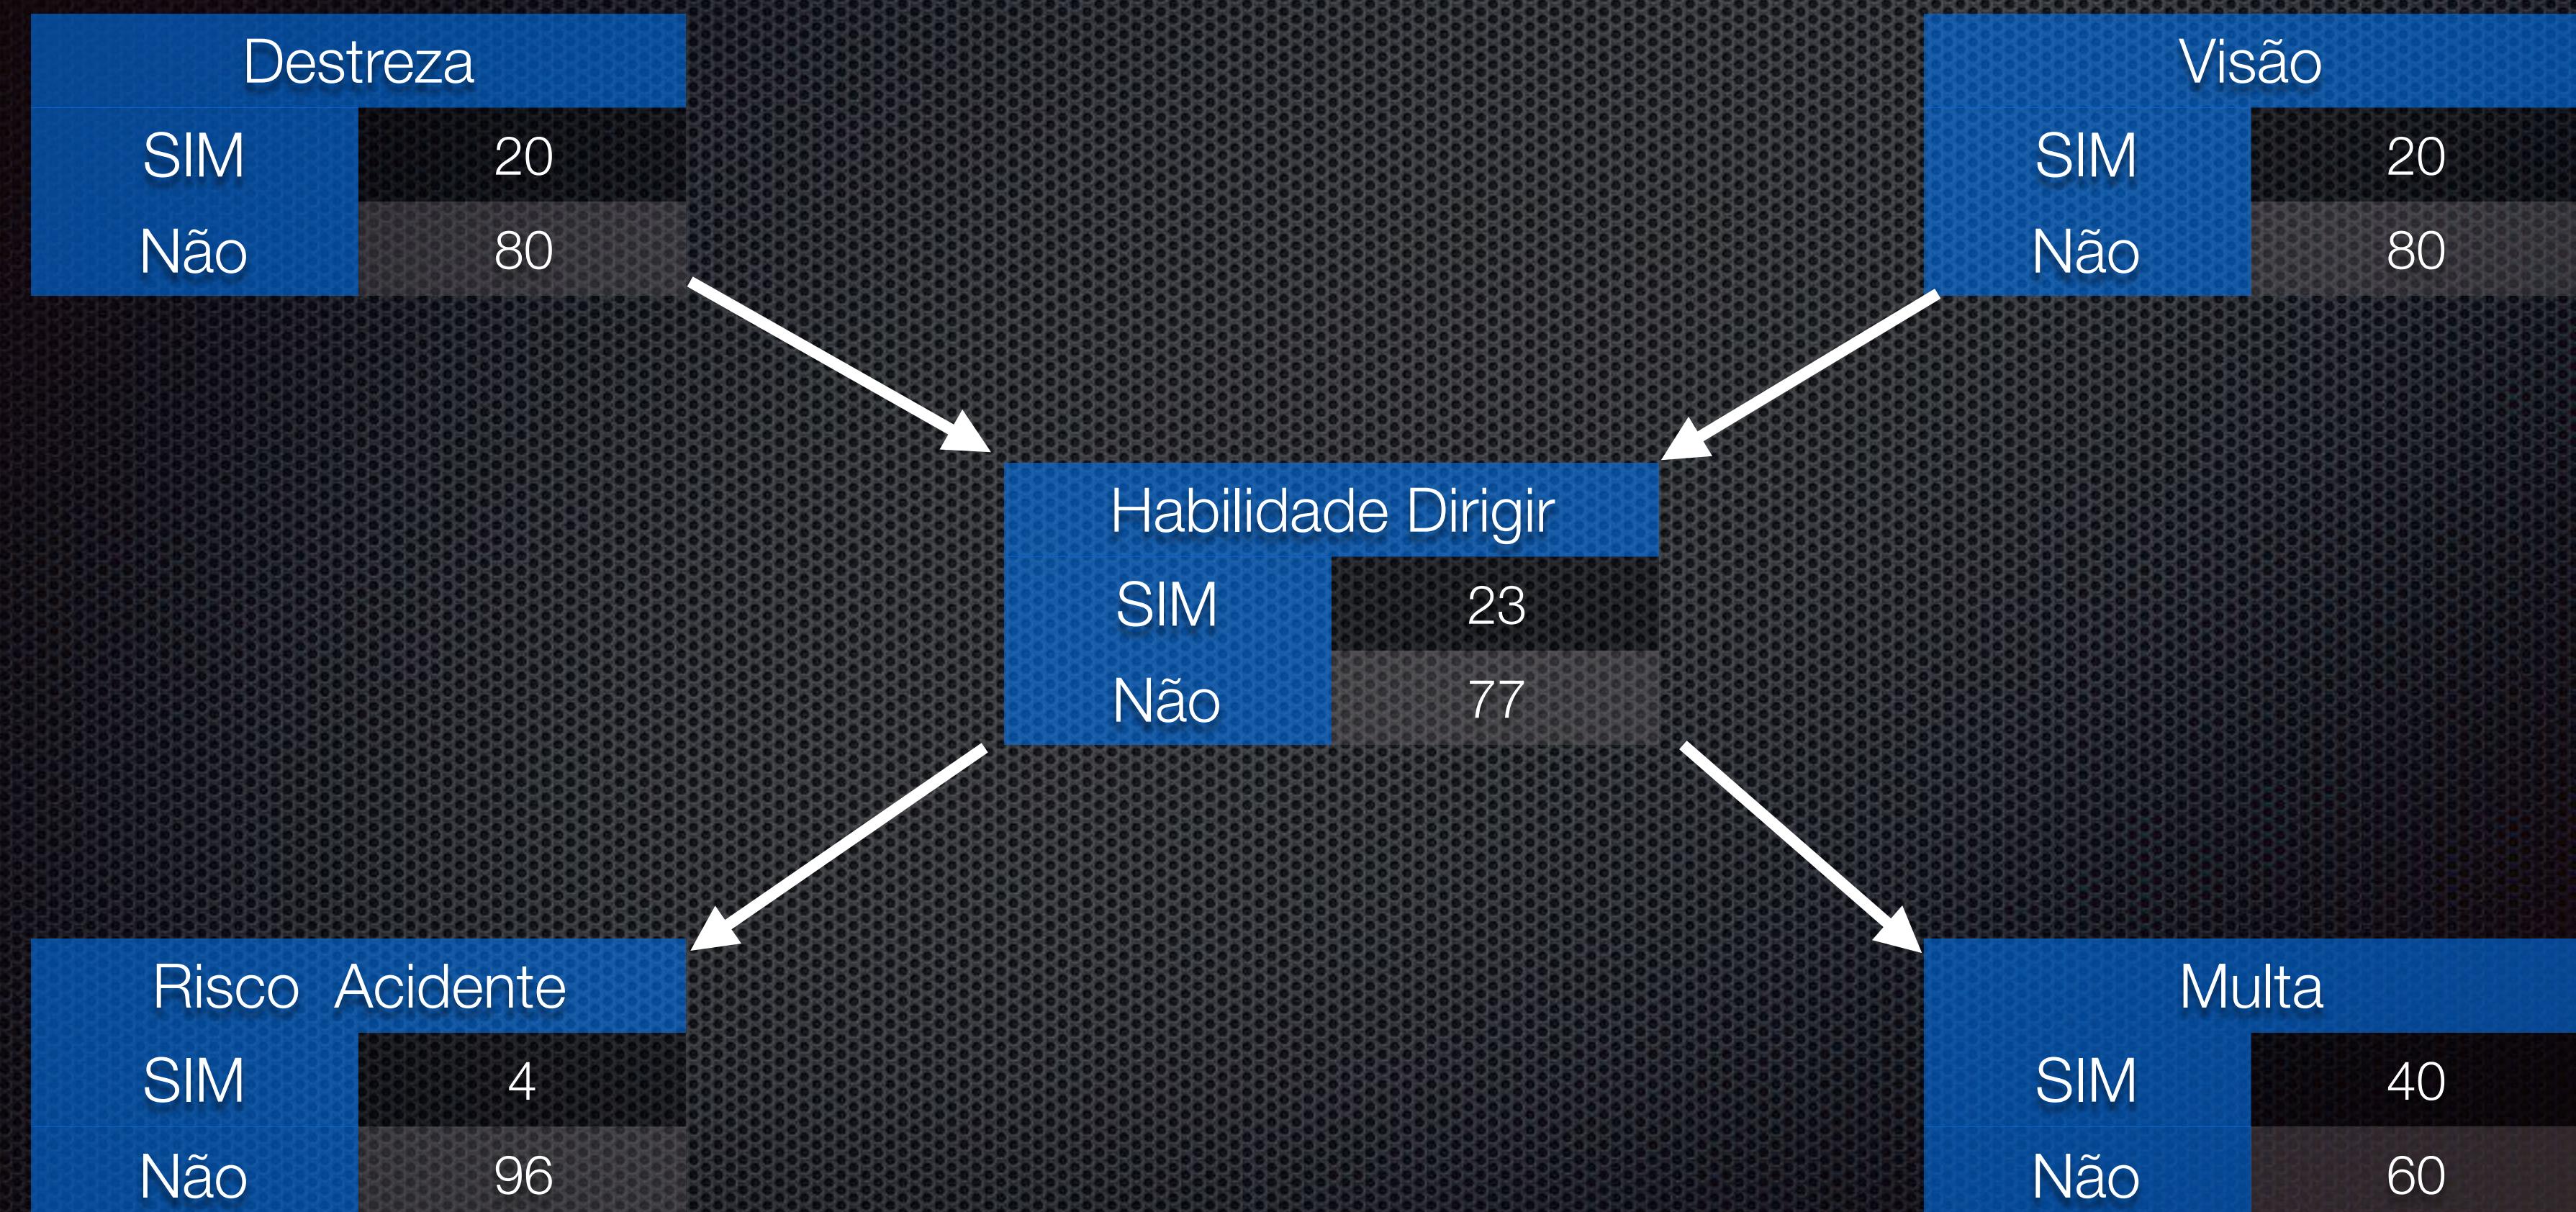
Passo 1 – Defina um conjunto de variáveis X que descrevam o domínio

- Destreza – variável que representa a destreza do indivíduo
 - Visão – variável que representa o quão o indivíduo enxerga bem;
 - Habilidade dirigir – variável que denota a habilidade de dirigir;
 - Risco acidente – variável que representa a probabilidade do indivíduo se envolver em acidentes;
 - Multa – variável que representa a probabilidade do indivíduo ser autuado.
-
- Por motivos de simplificação, todas variáveis possuem apenas dois estados:
 - sim e não.

Passo 2 – Defina a Estrutura da Rede



Passo 2 – Defina a Estrutura da Rede



Passo 3 – Pesos - Probabilidades a Priori

P(Destreza = SIM)

0,20

P(Visão = SIM)

0,20

Passo 3 – Pesos - Probabilidades Condicionais

Visão	Destreza	$P(\text{Habilidade Dirigir} = \text{SIM})$
SIM	SIM	0,95
SIM	NÃO	0,5
NÃO	SIM	0,5
NÃO	NÃO	0,05

Passo 3 – Pesos - Probabilidades Condicionais

Habilidade Dirigir

P (Risco Acidente = SIM)

SIM

0,001

NÃO

0.05

Habilidade Dirigir

P (Multa = SIM)

SIM

0,05

NÃO

0.5

Inferência em Redes Bayesianas

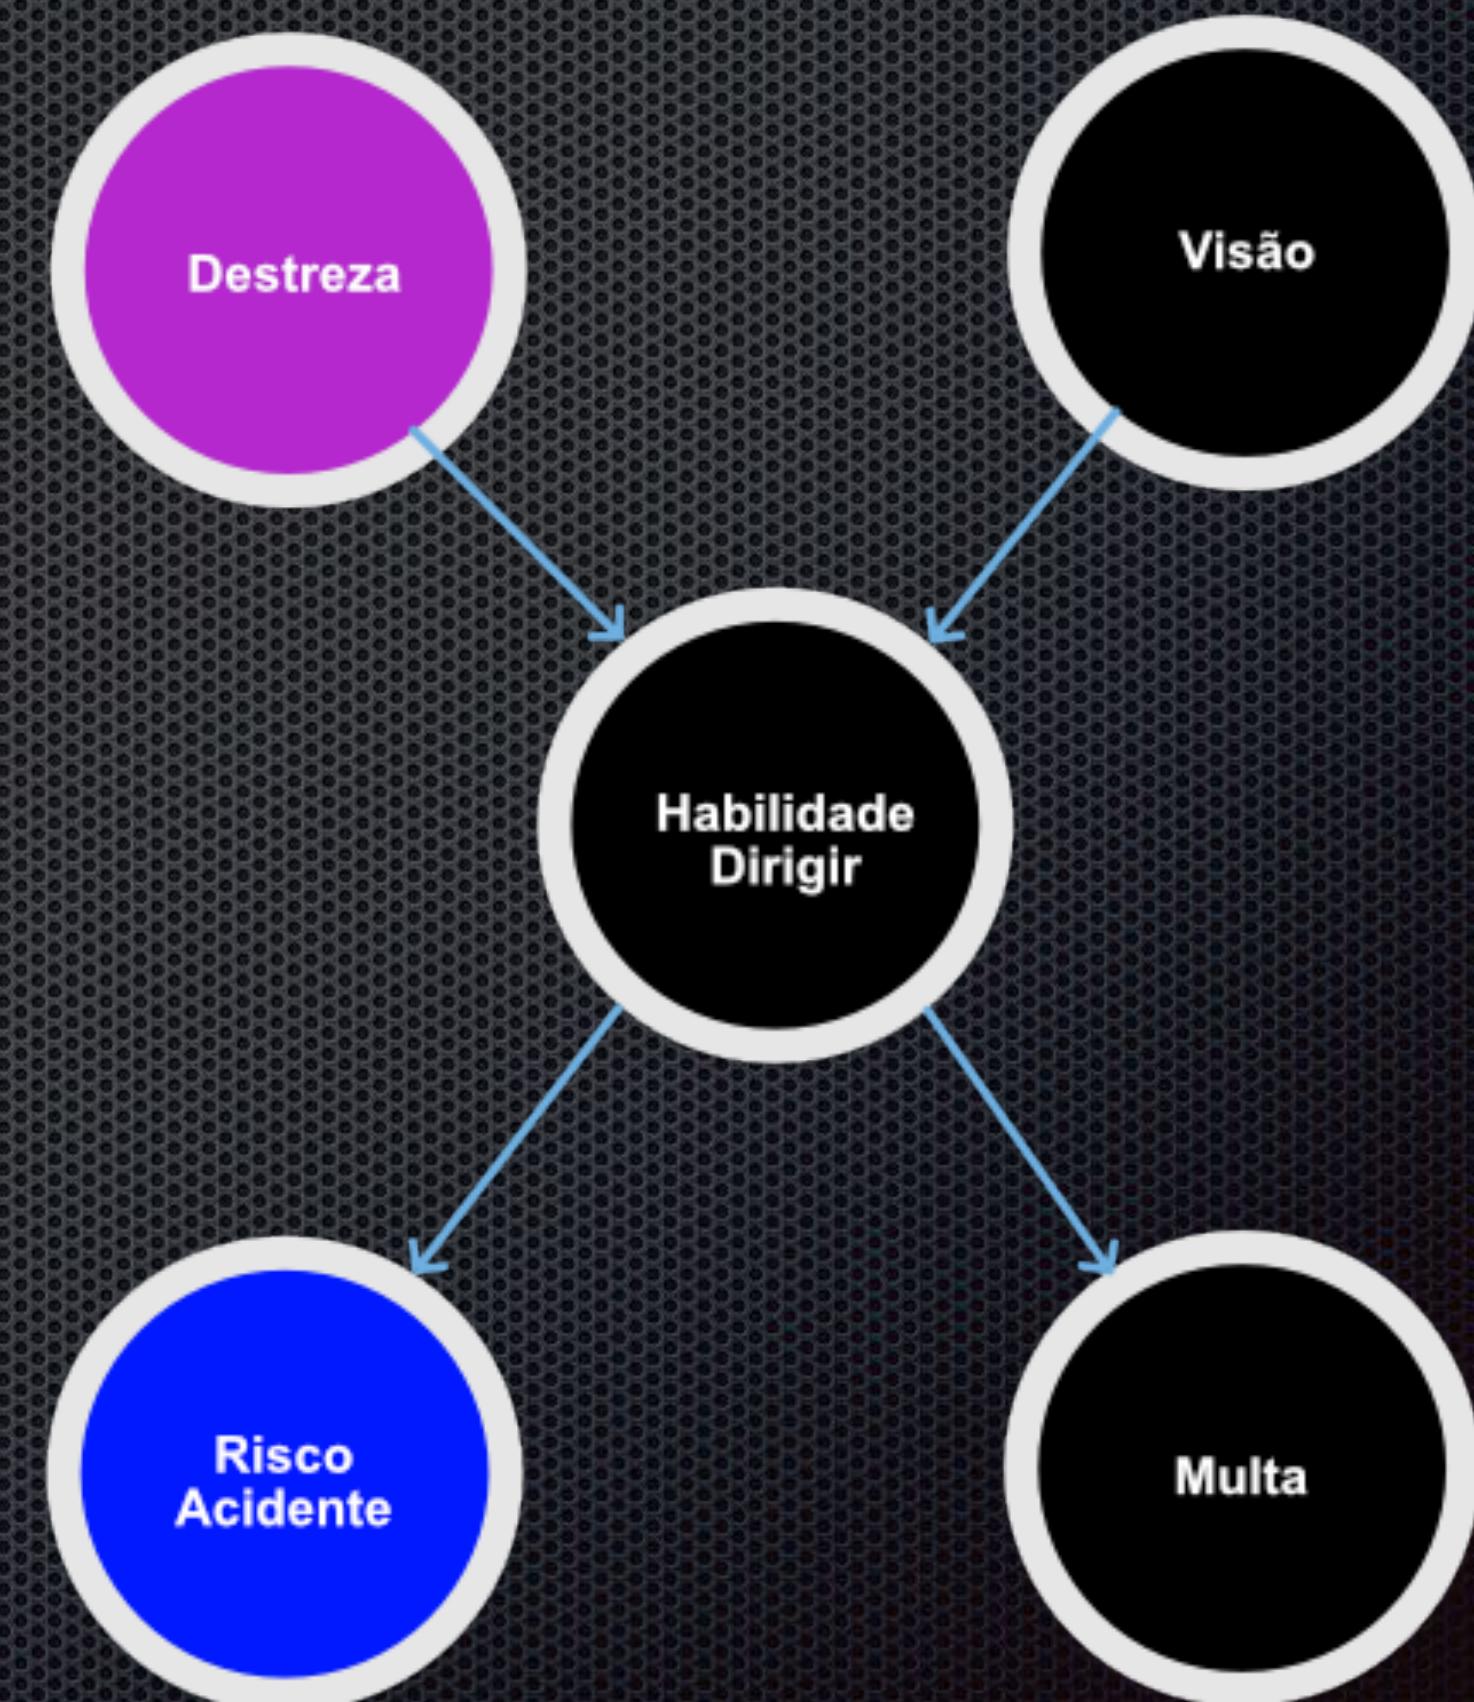
- Causal
- Diagnóstico
- Intercausal



Inferência Causal

Causal (das causas para os efeitos)

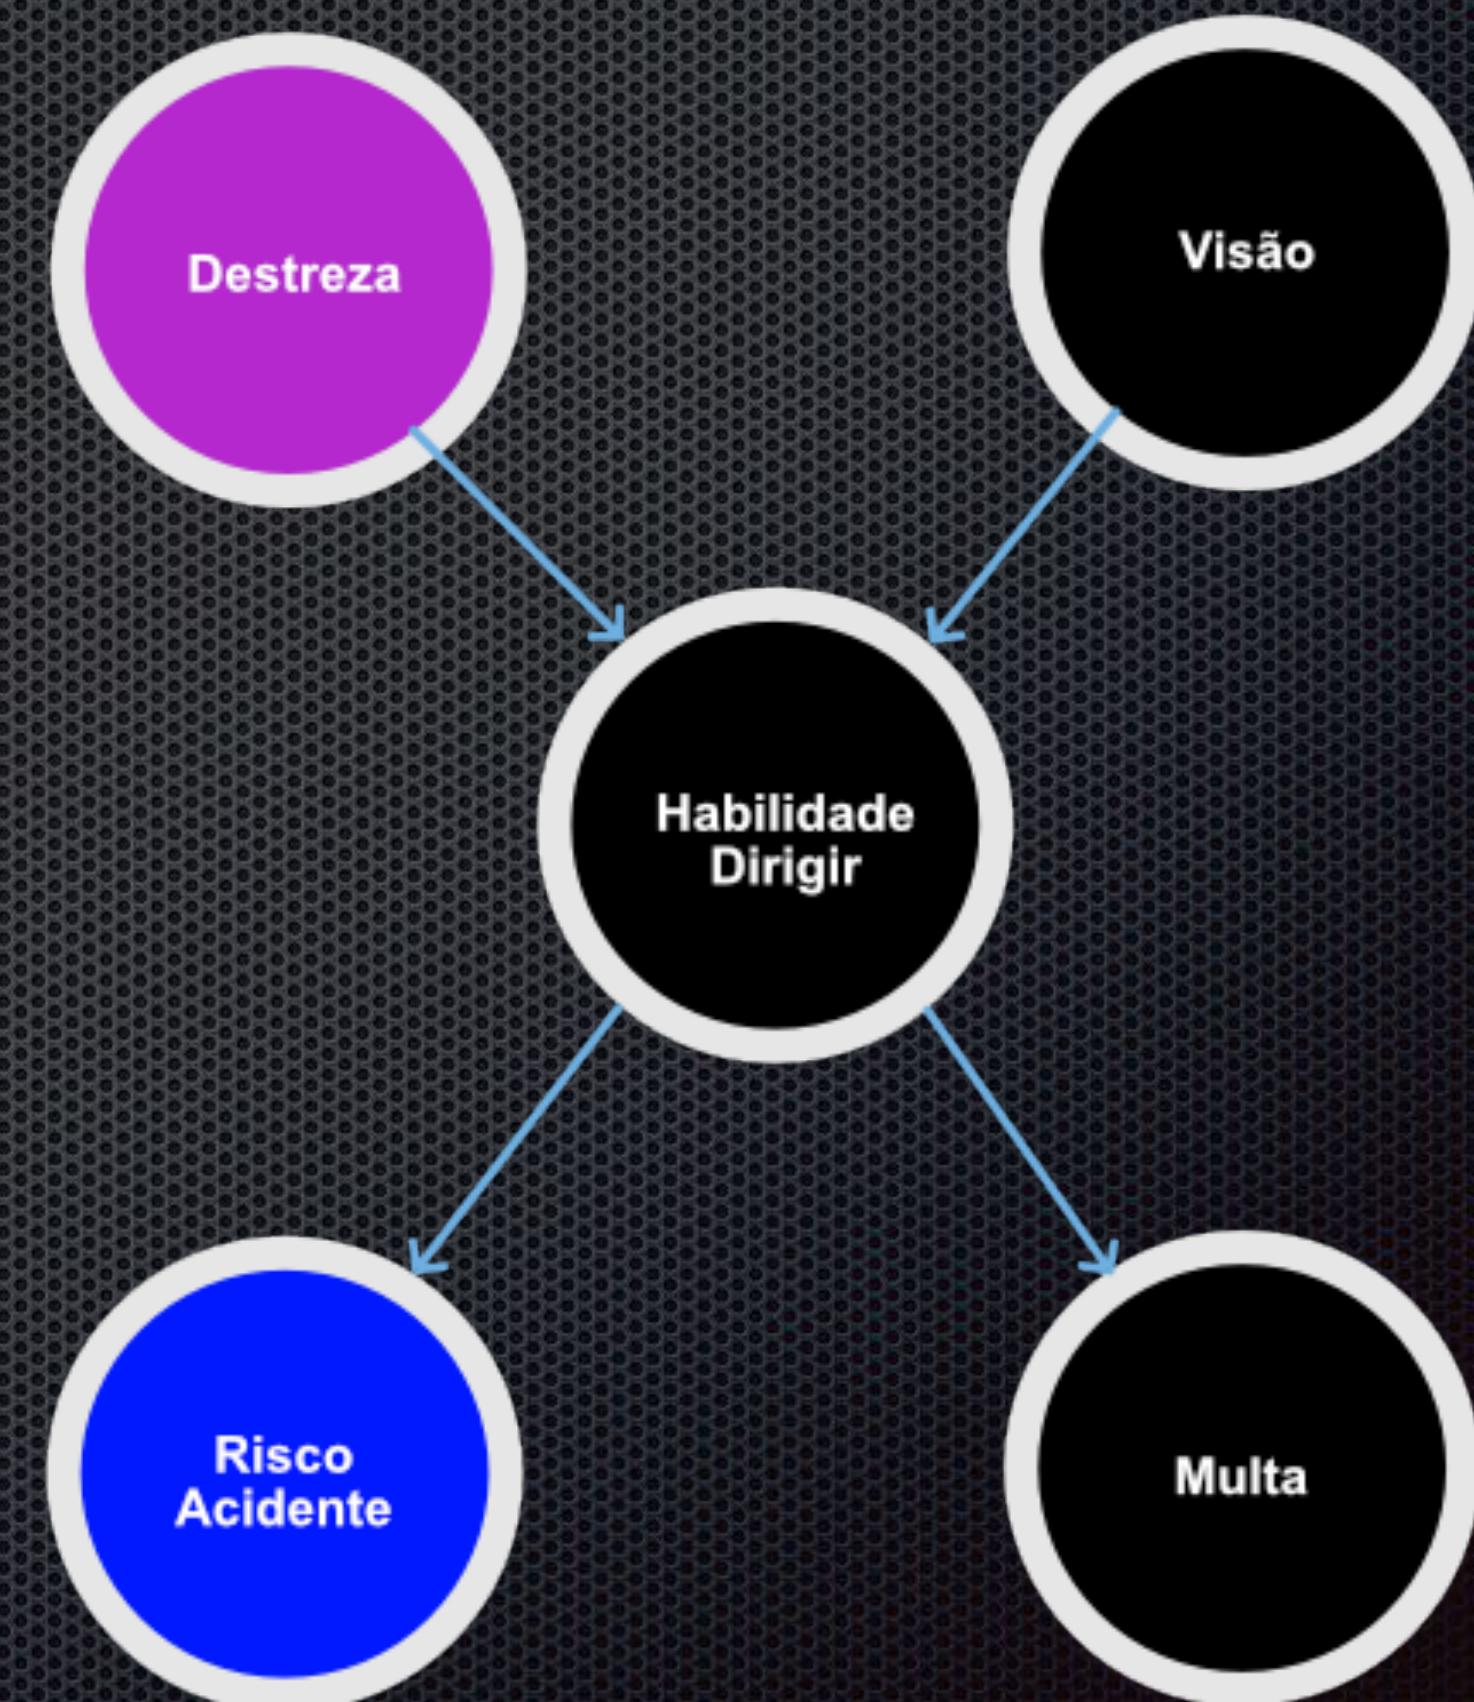
$$P(\text{ Risco Acidente} \mid \text{Destreza}) = 2.11\%$$



Inferência Diagnóstico

Diagnóstico (dos efeitos para as causas)

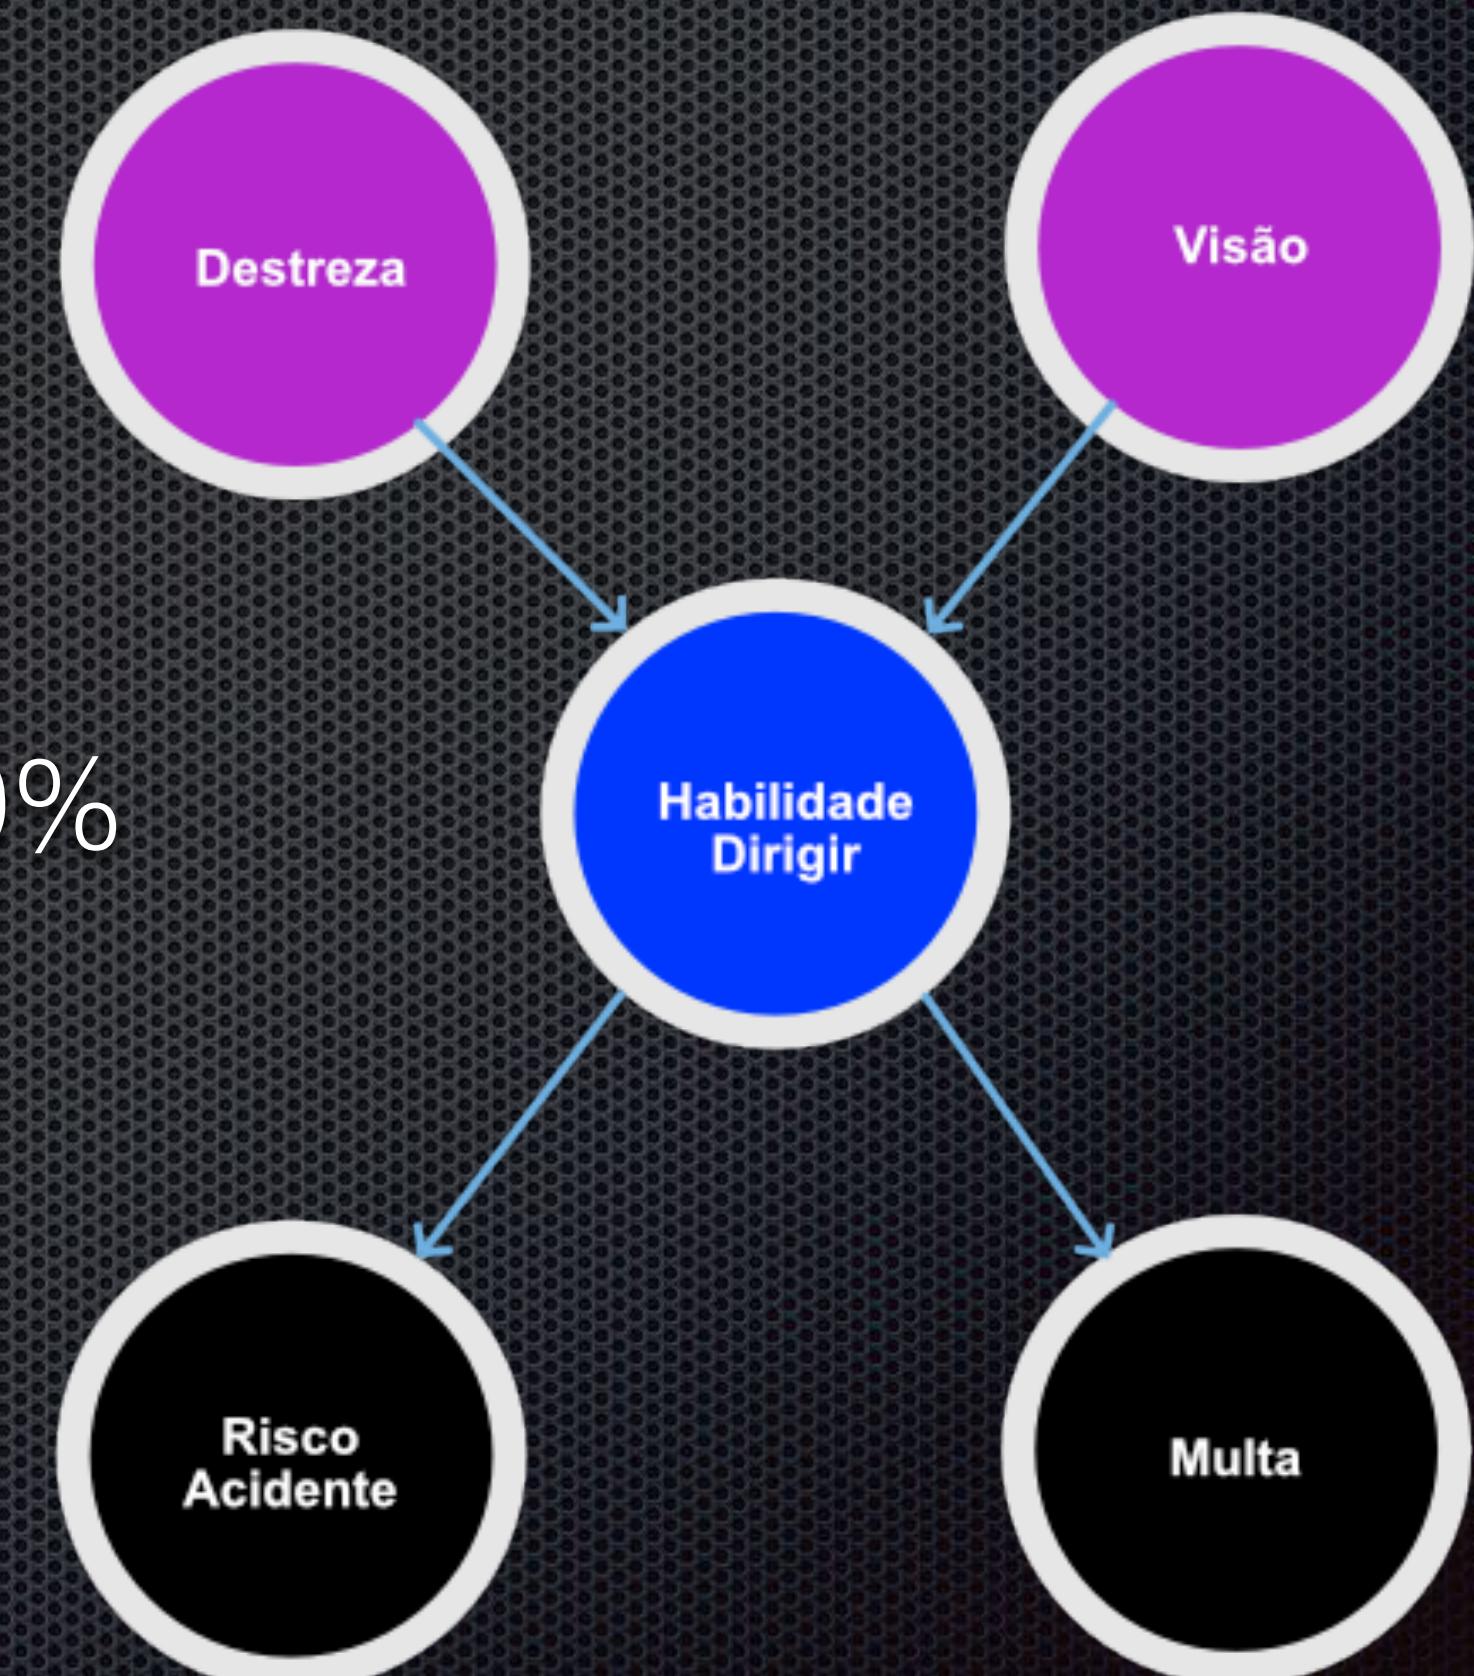
$$P(\text{ Destreza} \mid \text{ Risco Acidente}) = 10.9\%$$



Inferência Intercausal

Intercausal (entre causas e um efeito em comum)

$$P(\text{Destreza} \mid \text{Habilidade Dirigir}, \text{Visão}) = 32.9\%$$



Redes Bayesianas - Bibliotecas de Desenvolvimento

R

BnLearn / BnViewer

RStan

BayesAB

Python

SciPy

BayesPy

PyMC

Conclusão



Perguntas?



Obrigado

